

Análise Sociodemográfica e Econômica Nacional via SQL.

Transformando Dados Brutos do Censo IBGE em Inteligência Analítica Automatizada.

Amanda Moreira Rapold Souza
Loren Vitória Cavalcante Santos

Introdução e objetivos:

O Problema: Dados públicos brutos são massivos, mas vêm desestruturados e sem contexto de negócio

O Objetivo: Criar um pipeline completo que extrai dados do IBGE, limpa via Python, armazena em banco de dados e gera relatórios com interpretações automáticas via SQL puro.

Etapa 1: Coleta, Limpeza e Preparação (O Pipeline ETL)

Diagnóstico e Escolha das Ferramentas

Por que Python (Pandas) e não Excel?

- **Controle de Encoding:** O Excel corrompe acentos silenciosamente; no Python o tratamento é explícito.
- **Tipagem Avançada:** O Pandas garante consistência nas colunas numéricas sem arredondamentos imprevisíveis.
- **Reprodutibilidade:** O script em Python serve como documentação auditável de ponta a ponta.

Etapa 1: Coleta, Limpeza e Preparação (O Pipeline ETL)

Os 5 Problemas Resolvidos no Pipeline

- **1. Tratamento de Encoding:** Leitura em latin-1 e exportação limpa em utf-8.
- **2. Delimitador Ajustado:** Separação explícita de colunas colapsadas por ponto e vírgula.
- **3. Correção de Decimais:** Conversão do padrão brasileiro (vírgula) para o padrão computacional (ponto) nas colunas de área, IDH e finanças.
- **4. Nomenclatura SQL-Safe:** Remoção de tags HTML, colchetes e símbolos especiais. Conversão para o padrão de mercado snake_case (ex: rendimento_per_capita).
- **5. Enriquecimento de Dados:** Criação dinâmica da coluna regioao (Norte, Nordeste, etc.) via mapeamento de dicionários, essencial para as análises futuras.

Etapa 2: Ingestão e Inteligência em SQL

Ingestão de Dados e o Conceito de Automação

- **Persistência:** Dados salvos em um banco de dados relacional SQLite pela sua portabilidade e compatibilidade de sintaxe com PostgreSQL e MySQL.
- **A "Grande Virada" (Regra de Negócio):** Em vez de extrair números brutos e interpretá-los manualmente no Excel, as consultas SQL foram desenhadas com a estrutura CASE WHEN.
- **O Resultado:** O próprio banco de dados "mastiga" e categoriza as informações em colunas de status antes de exibi-las.

Etapa 3: Resolução dos Desafios Técnicos e Insights

Desafio 1 – Cálculo de Densidade Demográfica

- **A Lógica Técnica:** Operação aritmética direta ($\text{populacao} / \text{area_km2}$) com ordenação decrescente.
- **Automação (CASE WHEN):** Classificação automática em colunas de status: Alta, Média, Baixa ou Muito Baixa Densidade.
- **O que o Relatório Revelou (Insight Final):** Distrito Federal (489,06 hab/km²), Rio de Janeiro e São Paulo lideram o adensamento de forma isolada, enquanto estados como o Amazonas possuem imensos vazios demográficos (2,53 hab/km²).
- **Impacto Prático/Decisão:** Direcionamento macroeconômico urgente de infraestrutura urbana e transporte para as áreas saturadas vs. incentivos de ocupação/logística no Norte.

Etapas 3: Resolução dos Desafios Técnicos e Insights

Desafio 2 – Agregação Macrorregional

- **A Lógica Técnica:** Agrupamento por região geográfica (GROUP BY regioao) calculando simultaneamente a média simples de IDH e Renda Mensal por habitante.
- **Automação (CASE WHEN):** Classificação imediata das médias em faixas de status (ex: IDH Alto, Renda Baixa).
- **O que o Relatório Revelou (Insight Final):** Divisão socioeconômica explícita do país. Sul, Sudeste e Centro-Oeste performam com IDH e Renda Altos, enquanto Norte e Nordeste figuram com IDH Médio e Renda Baixa.
- **Impacto Prático/Decisão:** Formulação de políticas públicas federais de redistribuição de renda e fundos constitucionais de financiamento focados especificamente nos blocos Norte e Nordeste.

Etapa 3: Resolução dos Desafios Técnicos e Insights

Desafio 3 – Filtragem por Linha de Corte Dinâmica (Frota)

- **A Lógica Técnica:** Filtro avançado com Subquery Aninhada.
- **Automação (CASE WHEN):** Identificação em tempo real de estados Acima da Média ou Muito Acima da Média.
- **O que o Relatório Revelou:** Apenas 8 estados superam a média nacional de frotas. São Paulo distorce completamente a curva, registrando mais de 35 milhões de veículos (mais de 3 vezes a média nacional).
- **Impacto Prático/Decisão:** Adequação de malhas rodoviárias interestaduais e políticas de transição energética automotiva concentradas nesses 8 hubs logísticos dominantes.

Etapas 3: Resolução dos Desafios Técnicos e Insights

Desafio 4 – Análise de Vulnerabilidade Social

- **A Lógica Técnica:** Associação de múltiplos operadores lógicos (AND) para mapear concomitância: rendimento per capita < R\$ 1.500,00 E matrículas no ensino fundamental > 200.000.
- **Automação (CASE WHEN):** Subcategorização em níveis de Vulnerabilidade Crítica/Alta e Demanda Escolar.
- **O que o Relatório Revelou (Insight Final):** Cruzamento perfeito de alta demanda estudantil com extrema escassez de renda em 12 estados (todos do Norte e Nordeste), liderados pela criticidade do Maranhão (renda média de R\$ 945).
- **Impacto Prático/Decisão:** Direcionamento prioritário e proporcional de verbas complementares do Fundeb e programas de assistência social escolar direta para essas 12 regiões.

Etapas 4: Visualização e Dashboard

O Dashboard Interativo HTML

Por que HTML + Chart.js e não Power BI/Tableau?

- **Acessibilidade Universal:** Abre em qualquer navegador sem licenças ou instalações locais por parte do avaliador.
- **Controle Total:** Permite usar JavaScript puro para pintar os gráficos usando exatamente as mesmas categorias lógicas criadas pelo SQL (CASE WHEN).
- **Os Gráficos Adotados:** Barras horizontais ordenadas para rankings (D1), Eixo Y Duplo para escalas diferentes de IDH e Renda (D2), Linha flutuante dinamicamente sobre as frotas (D3) e Scatter Plot (Dispersão) para mapear a vulnerabilidade espacial (D4).

Conclusão

- **O projeto cobriu o ciclo completo da engenharia e análise de dados: extração, higienização rigorosa, estruturação relacional, automação de regras de negócio em SQL e entrega visual acessível.**
- **Os dados deixaram de ser apenas registros soltos do IBGE para se tornarem um motor automatizado de tomada de decisão governamental.**

Conclusão técnica

O projeto percorreu um pipeline completo de engenharia de dados:

```
Arquivo bruto (latin-1, ;, vírgula decimal, HTML nos headers)
    ↓ Python/pandas: 7 passos de limpeza
CSV limpo (UTF-8, ;, float64, snake_case, +coluna regioao)
    ↓ sqlite3: to_sql()
Banco SQLite (tabela censo, 27 linhas × 15 colunas)
    ↓ SQL puro: 4 queries com CASE WHEN + subquery
Resultados classificados automaticamente
    ↓ Chart.js/HTML: 4 tipos de gráfico + KPIs + filtros
Dashboard interativo entregável
```

Cada decisão técnica — de `encoding='latin1'` no `read_csv` ao eixo Y duplo no Chart.js — foi determinada pelos dados reais e pelos requisitos específicos do projeto, não por preferências arbitrárias.